

BO2-05

Traçabilité des données au niveau des colonnes

Rapport de réalisation - 8 octobre 2026
Branche de travail : ahmed-ikbel

1. Objectif du DSO

Rendre explicite la relation entre les champs sources, les transformations et les indicateurs finaux. À partir d'un indicateur, l'utilisateur doit pouvoir retrouver les colonnes utilisées, les règles de nettoyage et les conditions qui déterminent quelles lignes participent au calcul.

Le prototype construit un graphe à partir d'une exécution réelle du nettoyage BO2-02 et de trois calculs d'indicateurs. Il expose ce graphe dans Streamlit et conserve chaque exécution dans un historique local persistant.

2. Réalisation livrée

Composant	Réalisation
Graphe	Nœuds de datasets, colonnes, transformations et indicateurs ; relations typées et versionnées.
Navigation	Sélection d'un indicateur, affichage de ses ancêtres et inspection d'un nœud.
Calculs	Somme des montants, revenu moyen et somme des nombres de transactions.
Historique	Une exécution identifiée et datée, stockée localement dans SQLite.
Export	Graphe complet JSON avec paramètres de nettoyage et empreintes des données.

Fichiers concernés

- governance/lineage.py** : construction, parcours et stockage du graphe.
- pages/4_BO2_Lineage.py** : interface de navigation.
- tests/test_lineage.py** : tests des calculs et de la traçabilité.
- governance_app.py** : entrée commune des quatre DSO.

Sources, règles et indicateurs

3. Une exécution sur les données du projet

La page utilise les 500 lignes synthétiques produites par `generate_dirty_dataset`, avec la graine par défaut 2026. La politique de nettoyage 1.2.0 est exécutée sur une copie. Les cinq champs métier sont `age`, `income`, `spending_score`, `transaction_amount` et `num_transactions`.

Une ligne n'est retenue pour les indicateurs que si aucune de ces cinq colonnes ne présente une exception de nettoyage non résolue. Sur le dataset actuel, 196 lignes sont retenues et 304 sont exclues des agrégations. Les lignes exclues ne sont pas supprimées du dataset source.

4. Définitions des trois indicateurs

Indicateur	Formule sur les lignes retenues
Somme des montants	<code>sum(transaction_amount)</code>
Revenu moyen	<code>mean(income)</code>
Total des transactions	<code>sum(num_transactions)</code>

Ces définitions sont celles de la démonstration, enregistrées avec une version sémantique 1.0.0. La somme des montants n'est pas appelée chiffre d'affaires : le sens métier du champ `transaction_amount` ne justifie pas cette interprétation. Aucun montant n'est multiplié par un nombre de transactions sans règle approuvée.

Si aucune ligne n'est éligible, la valeur des indicateurs est absente (None dans le moteur) et l'interface affiche Non calculable, plutôt qu'un résultat artificiel.

5. Deux types de dépendances à distinguer

Dépendance de valeur : la somme des montants agrège `transaction_amount`. C'est la colonne qui fournit les nombres additionnés.

Dépendance de sélection : `age`, `income`, `spending_score`, `transaction_amount` et `num_transactions` déterminent toutes l'éligibilité des lignes. Par exemple, un âge invalide exclut une ligne même si son montant est lisible. Le graphe expose cette influence sur le résultat.

La sélection complète peut réduire fortement la couverture et introduire un biais. L'indicateur décrit le sous-ensemble retenu, pas nécessairement toute la population initiale.

Graphe et conservation des preuves

6. Structure du graphe

Le graphe complet de la démonstration comporte **24 nœuds** et **34 relations**. Le parcours d'un indicateur n'affiche que ses ancêtres pertinents. Les autres indicateurs ne sont pas inclus dans ce parcours.

Type de nœud	Informations conservées
Dataset	Nom, nombre de lignes et empreinte des données sources ou nettoyées.
Colonne	Champ source, champ nettoyé ou champ éligible au calcul.
Nettoyage	Identifiant de règle, politique 1.2.0, nombres de changements et d'exceptions pour la colonne.
Filtre qualité	Formule du filtre, effectifs retenus et exclus.
Indicateur	Valeur, formule, version sémantique et nombre de lignes contributrices.

Les relations distinguent notamment input, produces, eligibility_dependency, value_dependency, row_selection et aggregation. Chaque relation porte l'identifiant de l'exécution et la version 1.0.0 de sa représentation.

7. Versionnement et historique

Chaque exécution reçoit un UUID et une date UTC. Le schéma du graphe porte une version ; le manifeste de nettoyage conserve la version et une copie de la politique ainsi que ses empreintes SHA-256 et celles des données avant/après.

Le stockage se trouve dans **output/lineage/runs.sqlite3**. Une table runs contient l'identifiant, la date et le graphe sérialisé en JSON. Les exécutions précédentes peuvent être rechargées et inspectées après une nouvelle session. Un nouvel enregistrement ne remplace pas silencieusement un identifiant existant.

La base conserve les métadonnées, les compteurs et les valeurs agrégées des indicateurs, sans enregistrer les lignes sources ou des valeurs personnelles individuelles. L'export JSON contient le graphe complet, pas uniquement le parcours actuellement affiché.

8. Responsabilités représentées

ETL : dépendances des transformations ; **SEM** : formules des indicateurs ; **DQ** : règles et compteurs de nettoyage ; **XAI** : exposition du parcours. Ces rôles correspondent ici à des fonctions locales, pas à des agents autonomes connectés à des services externes.

Démonstration, tests et limites

9. Parcours dans Streamlit

1. Lancer `.venv\Scripts\python -m streamlit run governance_app.py`.
2. Ouvrir **BO2-05 · Traçabilité**.
3. Cliquer sur **Calculer les indicateurs et enregistrer la traçabilité**.
4. Choisir une exécution dans l'historique daté en UTC.
5. Choisir l'indicateur à retracer et observer ses dépendances.
6. Sélectionner un nœud pour consulter ses attributs.
7. Consulter les relations, la politique et les empreintes, puis exporter le JSON.

Le graphe est rendu avec Streamlit Graphviz. La navigation s'effectue par les sélecteurs d'indicateurs et de nœuds ; les boîtes du graphe ne constituent pas des liens interactifs autonomes.

10. Vérifications réalisées

19 tests réussis sur l'ensemble des DSO au moment de la livraison, dont trois tests propres à BO2-05 :

Test	Vérification
Valeurs et dépendances	Somme des montants identique à un calcul indépendant sur les lignes retenues ; 196 contributeurs ; présence du champ agrégé et du champ age dans le parcours, exclusion des indicateurs sans lien.
Persistance et cas vide	Écriture puis relecture fidèle du graphe dans SQLite ; base absente gérée ; indicateurs sans valeur lorsque le dataset est vide.
Interface	Affichage des trois indicateurs et changement d'indicateur à retracer sans erreur Streamlit.

11. Limites du prototype

La traçabilité est instrumentée explicitement pour ce pipeline : nettoyage, filtre qualité et trois agrégations. Elle n'est pas déduite automatiquement de n'importe quel code Python ou requête SQL. Les étapes PII et anomalies ne sont pas encore reliées à ce graphe.

Il n'existe pas de serveur OpenLineage, de base Neo4j ou de connecteur à un entrepôt externe. Aucune jointure fictive n'est ajoutée. Le stockage est local et ne propose ni contrôle d'accès de production, ni signature cryptographique, ni garantie d'inaltérabilité de l'historique.

Suites possibles

Instrumenter les étapes PII et anomalies ; ajouter des dépendances lors de vraies jointures ; gérer l'évolution des versions sémantiques ; connecter la traçabilité à un stockage central et à un tableau de bord métier. Les empreintes identifient les données mais ne remplacent pas leur archivage pour une reproduction future.